

**Министерство образования Российской Федерации**

**МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ**  
**УНИВЕРСИТЕТ**  
**им. Н.Э. БАУМАНА**

Факультет: Информатика и системы управления  
Кафедра: Информационная безопасность (ИУ8)

**ИНТЕЛЛЕКТУАЛЬНЫЕ ТЕХНОЛОГИИ**  
**ИНФОРМАЦИОННОЙ БЕЗОПАСНОСТИ**

**Лабораторная работа №3 на тему:**  
**«Применение однослойной нейронной сети с линейной**  
**функцией активации для прогнозирования временных**  
**рядов»**

Вариант 8

**Преподаватель:**  
Коннова Н. С.

**Студент:**  
Песоцкий А. А.

**Группа:**  
ИУ8-61

Москва, 2020

## Цель работы

Изучить возможности однослойных НС в задачах прогнозирования временных рядов методов скользящего окна (авторегрессия)

## Постановка задачи

На временном интервале  $[a, b]$  задан дискретный набор значений функции  $x(t)$ . Количество точек  $N=20$ , расположение – равномерное. Методом «скользящего окна» спрогнозировать поведение функции  $x(t)$  на  $N$  точках последующего интервала  $(b, 2b - a]$ . Для решения использовать однослойную НС с количеством нейронов  $p$  и линейной функцией активации. Исходное количество нейронов (длина окна)  $p = 4$ . Обучение производить методом Видроу — Хоффа. Исследовать влияние количества эпох  $M$  обучения и коэффициента обучения  $\eta$  на средне-квадратичную погрешность приближения  $\varepsilon = \sqrt{\sum_i [x(t_i) - \tilde{x}(t_i)]^2}$ .

Исследовать процесс прогнозирования при постепенном изменении (уменьшении/увеличении) размера окна  $p$ . Сделать выводы по результатам численного эксперимента.

## Ход работы

### 1. Функция и её прогноз

Рассмотрим прогноз функции  $X(t) = \sin^2 t$  по 20 равностоящим исходным значениям  $x$ , заданным на интервале  $[0, 2]$ . Выберем начальную длину окна  $p = 4$ , норму обучения  $\eta = 0.3$ .

Зададим нулевые начальные веса:  $W = [0, 0, 0, 0, 0]$ . На рисунках 1 и 2 показаны график функции и её прогноз (круглые маркеры) на интервале  $t \in [2, 4]$  при различном количестве эпох обучения  $M$ .




Рисунок 1. Функция и её прогноз при  $M = 200$ ,  $\varepsilon = 0.427$ .




Рисунок 2. Функция и её прогноз при  $M = 500$ ,  $\varepsilon = 0.0021$ .

Вектор весовых коэффициентов при  $M = 500$  равен:

$W = [0.05285147721580807, -0.5074918755160587, -0.01791562604724876, 0.4735198676502398, 0.9462085955329141]$

## 2. Зависимость погрешности от числа эпох и нормы обучения:

Построим графики зависимости погрешности  $\varepsilon$  от числа эпох  $M$  с различными нормами обучения:




Рисунок 3. Норма обучения  $\eta = 0.3$




Рисунок 4. Норма обучения  $\eta = 0.7$ .

Построим графики зависимости погрешности  $\varepsilon$  от нормы обучения  $\eta$  с различным количеством эпох  $M$ :




Рисунок 5.  $M = 200$




Рисунок 6.  $M = 500$

Попарно сравнив каждый из полученных графиков, можем сделать вывод, что при одинаковом наборе эпох с увеличением нормы обучения увеличивается крутизна графика, что свидетельствует о более быстром достижении меньшей погрешности. Сама же финальная погрешность на последней эпохе становится меньше с ростом нормы обучения.

В случае сравнения графиков с одинаковым набором норм обучения, но разным количеством эпох, наблюдаем очевидную тенденцию: чем больше эпох, тем круче график и меньше финальная погрешность.

### 3. Прогнозирование при изменении размера окна:

Проведём численный эксперимент, увеличивая размер окна от 4 до 19, на двух случаях:

а)  $\eta = 0.3$ ,  $M = 500$

б)  $\eta = 0.7$ ,  $M = 500$




Рисунок 7. Случай а




Рисунок 8. Случай б

Проанализировав полученные результаты, можем сделать вывод, что с увеличением размера окна уменьшается точность обучения, следовательно возрастает количество эпох, необходимое для получения приемлемого результата, то есть возрастает погрешность.

## **Выводы**

В ходе выполнения лабораторной работы были изучены возможности однослойных НС в задачах прогнозирования временных рядов методом скользящего окна (авторегрессия).

В ходе выполнения работы пришли к выводу, что число эпох обучения  $M$  и норма обучения обратно пропорциональны погрешности  $\varepsilon$ : чем больше  $M$  и норма, тем меньше среднеквадратическая погрешность приближения  $\varepsilon$ .

## Приложение А.

### Файл 'prediction.py'.

```
from computation import *
import numpy as np

"""
Функция обучения
:param points_number: число точек интервала
:param window_size: размер окна
:param norm: норма обучения
:param vector_w: набор весов
:param epoch_max: максимальное число эпох
:param return: набор весов, последняя погрешность
"""

def sliding_window_learn(points_number, window_size, norm, vector_w, epoch_max):
    points = np.linspace(0, 4, 40)
    x = int(window_size)

    values = list()
    for pt in points[0:20]:
        values.append(function(pt))

    epoch = 0

    while epoch < epoch_max:

        s = 0
        f = x

        while f < points_number:

            # подсчёт net
            net = 0
            for (v, w) in zip(values[s:f], vector_w[1:]):
                net += v * w
            net += vector_w[0]

            # Вычисление delta
            delta = values[f] - net

            # Пересчёт весовых коэффициентов
```



```

for (j, v) in zip(range(1, len(vector_w)), range(s, f)):
    vector_w[j] += get_dw(delta, norm, values[v])
vector_w[0] += get_dw(delta, norm, 1)

```

```

s += 1

```

```

f += 1

```

```

epoch += 1

```

```

return vector_w

```

```

'''

```

Функция прогнозирования графика

:param points\_number: число точек интервала

:param window\_size: размер окна

:param vector\_w: набор весов

:param return: спрогнозированные значения функции

```

'''

```

```

def predictive_plot(points_number, window_size, vector_w):

```

```

    points = pts = np.linspace(0, 4, 40)

```

```

    x = int(window_size)

```

```

    y = list()

```

```

    for pt in points:

```

```

        y.append(function(pt))

```

```

    values = list()

```

```

    new_points = points[(20 - x):20]

```

```

    for pt in new_points:

```

```

        values.append(function(pt))

```

```

    sec_values = list()

```

```

    sec_points = points[20:]

```

```

    for pt in sec_points:

```

```

        sec_values.append(function(pt))

```

```

    s = 0

```

```

    f = x

```

```

    delta_list = list()

```

```

    while f < points_number + x:

```

```

net = 0
for (v, w) in zip(values[s:], vector_w[1:]):
    net += v * w
net += vector_w[0]
values.append(net)

delta = sec_values[s] - net
delta_list.append(delta)

s += 1
f += 1

epsilon = get_epsilon(delta_list)

graph_plot(points, values, y, 20, x, 'x', 'x(t)', 1)

return values, epsilon

'''
Функция тестирования для отчёта
:param N: число точек интервала
:param ws: размер окна
:param W: набор весов
:param M: максимальное число эпох
'''

def test(N, ws, W, M):
    norm_list = list()
    e_list = list()
    # for epoch in range(100, 1500, 100):
    # for norm in np.arange(0.1, 0.7, 0.05):
    for w_size in range(4, 20):
        W = [0,0,0,0,0]
        new_W = sliding_window_learn(N, w_size, 0.7, W, 500)
        vc, e = predictive_plot(N, w_size, new_W)
        norm_list.append(w_size)
        e_list.append(e)
    style.use('seaborn')
    style.use('ggplot')
    plt.plot(norm_list, e_list)
    plt.xlabel('window size, p')
    plt.ylabel('epsilon')

plt.grid(True)

```

```
plt.show()
```

```
if __name__ == "__main__":
```

```
    N = int(input('Enter N:'))
```

```
    M = int(input('Enter M:'))
```

```
    p = int(input('Enter sliding window size:'))
```

```
    nu = float(input('Enter nu:'))
```

```
    W = list()
```

```
    for i in range(0, p + 1):
```

```
        W.append(0)
```

```
    vec = sliding_window_learn(N, p, nu, W, M)
```

```
    temp, eps = predictive_plot(N, p, vec)
```

```
    W = list()
```

```
    for i in range(0, p + 1):
```

```
        W.append(0)
```

```
    # test(N, p, W, M)
```

```
    print(vec)
```

```
    print(eps)
```

*Файл 'computation.py'.*

```
from math import sin, tan
```

```
from math import sqrt
```

```
import matplotlib.pyplot as plt
```

```
import matplotlib.style as style
```

```
import matplotlib as mpl
```

```
"""
```

```
Исходная функция
```

```
:param t: параметр t
```

```
:param return: значение функции
```

```
"""
```

```
def function(t):
```

```
    return (sin(t)) ** 2
```

```

"""
Функция вычисления эпсилон
:param dlist: набор дельт
:param return: значение эпсилон
"""

def get_epsilon(dlist):
    epsilon = 0
    for delta in dlist:
        epsilon += delta**2
    return sqrt(epsilon)

"""
Функция вычисления коррекции веса
:param delta: дельта
:param return: значение коррекции
"""

def get_dw(delta, norm, x):
    return norm * delta * x

"""
Функция построения графика
:param x_array: значения x
:param y_array1: первый набор значений y
:param y_array2: второй набор значений y (для типа 1)
:param start_x: начальная точка x
:param start_y: начальная точка y
:param label_x: название гор. оси
:param label_y: название верт. оси
:param plot_type: тип графика
"""

def graph_plot(x_array, y_array1, y_array2, start_x, start_y, label_x, label_y, plot_type):
    style.use('seaborn')
    style.use('ggplot')
    plt.grid(True)
    if plot_type == 1:
        plt.plot(x_array, y_array2)
    plt.plot(x_array[start_x:], y_array1[start_y:], 'o')
    plt.xlabel(label_x)
    plt.ylabel(label_y)
    mpl.style.use('bmh')
    plt.show()

```

